

Token 运营平台 · 双控制台 Demo 设计说明

交互演示的页面清单、设计依据与对标映射 —— 配合演示链接阅读

版本	v2 · 2026-08-28(v1 初版 + v2 按 OpenRouter 最新 workspace 制控制台实测补齐治理与观测能力)
平台运营端	https://diaosj.info/token-console-demo/ —— 平台方内部使用:管租户/供给渠道/路由/计费毛利(深色侧栏)
租户控制台	https://diaosj.info/token-portal-demo/ —— 客户企业管理员使用:看用量/管 Key/配偏好(浅色侧栏,对标 OpenRouter 客户侧)
形态	纯前端静态页面 + 模拟数据;演示的是交互形态与信息架构,不代表真实计量。两页顶部横幅互链并标注各自视角。
上游文档	《token-platform-roadmap》(架构与分期)·《ops-console-design》(运营端 IA 与线框)·《newapi-openrouter-1route》(竞品调研)

0. 为什么是两个控制台

Token 网关业务天然有两个使用面,对应两类完全不同的用户与任务:

	平台运营端(深色)	租户控制台(浅色)
给谁用	平台自己的运营/SRE/客户成功/财务	客户企业的管理员与开发者
核心问题	"平台今天挣不挣钱、渠道健不健康"	"我花了多少钱、怎么管好我的 Key 和策略"
信息密度	高:毛利、渠道健康墙、对账差异	中:自己的用量、账单、偏好
对标物	无公开完整参照(OpenRouter 运营端不可见)——设计为"渠道管理 + 租户层级 + 下钻观测 + 毛利对账"的组合	OpenRouter 客户侧控制台,逐项看齐 + 国内 2B 本土化


两个 demo 用深色/浅色侧栏做视觉区分,避免演示时混淆视角;每页底部标注该页对标的能力与设计意图。

1. 通用设计原则

- 导航按角色任务分区,不按数据库对象分区——运营端五类角色(SRE/运营/客户成功/财务/管理员)高频页面几乎不重叠,每个一级导航对应一类人的主任务。
- 钱和健康永远第一屏:运营端总览 = 请求/成功率/成本/营收/毛利 + 渠道健康墙 + 待办告警;租户端总览 = 消费/预算/缓存节省/混合单价。
- 每张表都可下钻:租户 → 项目 → Key → 单请求 Trace(路由决策 → 上游耗时 → 逐 token 计量),对齐 Langfuse 式观测交互。
- 阶段标注诚实:demo 内 P1/P3 徽章标明该页在 roadmap 中的交付阶段,概念页明确写"概念页",不虚标完成度。

2. 平台运营端 —— 逐页设计说明

2.1 总览(P0)



一屏回答"平台现在怎么样":七卡 KPI 把运营最关心的链条排成一行——请求量 → 成功率 → 延迟 → 上游成本 → 客户营收 → 毛利(全品类竞品都没有毛利视图,这是运营端的差异核心)。右侧渠道健康墙 = 12 个供给渠道的红黄绿实时状态,点击直达;下方待办告警把"熔断/余额/配额/异常/价格"五类事件变成带操作按钮的工作流入口,而不是只读列表。

2.2 租户管理(P0)



客户成功的主页面:租户 → 套餐 → 项目数 → 用量 → 预算使用进度条 → 状态,一行看完一个客户。层级模型(租户→项目→Key)借鉴阿里百炼的业务空间,是单人站长型开源方案普遍缺失的企业层级;详情抽屉内可开通项目、发 Key、调配额。

2.3 渠道管理(P0)

Token 清算平台

清算系统 (Token)

首页

账户管理

渠道管理

模型管理

退出策略

风控策略

运营中心

统计

模型管理

退出策略

风控策略

运营中心

统计

渠道管理

10个渠道 | 新增 0 个渠道

搜索渠道 / 快速创建

新增渠道

批量渠道

名称	代码	币种/地区	状态	PKB / PKB	ROI 策略	总资产	收益 / 亏损	操作
DS-火山	火山引擎	Stepbank x3	● 健康	0.6x / 1.8x	0.00%	¥12,200	[50] / P1	渠道 / 详情
DS-官方	DeepBank	Stepbank x3	● 健康	0.6x / 2.4x	0.00%	¥1,203 A	[30] / P1	渠道 / 详情
Kini-官方	丹之跨境	kini x2	● 半开策略	1.1x / 4.2x	1.8% T	¥18,090	[40] / P1	渠道 / 详情
Kini-鑫鼎	鑫鼎跨境 A	kini x2	● 超期中 50s	— / —	0%	¥1,880	[10] / P2	渠道 / 详情
Gwen-鑫鼎	阿墨跨境	gwen x4	● 健康	0.7x / 2.1x	0.00%	¥98,830	[60] / P1	渠道 / 详情
Gwen-官方	阿墨官	gwen x4	● 健康	0.6x / 2.8x	0.04%	¥21,050	[25] / P2	渠道 / 详情
GLM-官方	智游	glm x2	● 健康	0.6x / 2.8x	0.00%	¥10,300	[30] / P1	渠道 / 详情
GLM-鑫鼎	蜂巢流动	glm x2	● 健康	0.9x / 2.9x	0.08%	¥12,710	[20] / P2	渠道 / 详情
蓝粉-官方	火山方舟	bluepod x2	● 健康	0.5x / 1.6x	0.00%	¥33,270	[40] / P1	渠道 / 详情
MM-官方	MinMax	wormex x1	● 健康	1.0x / 3.1x	0.00%	¥6,400	[15] / P2	渠道 / 详情
DS-蜂巢	蜂巢流动	stepbank x2	● 健康	0.1x / 2.1x	0.07%	¥5,320	[15] / P2	渠道 / 详情
Embed-鑫鼎	阿墨鑫鼎	embedding x2	● 健康	0.1x / 0.3x	0.01%	(合并计算)	[50] / P1	渠道 / 详情

新增渠道

新增渠道(按地区/币种筛选)

新增渠道(按策略/ROI/ROI)

新增渠道(按资产/收益/亏损)

Token 清算平台 | 运营策略与风控策略 | 风控策略与风控策略 | 风控策略与风控策略

SRE 的主页面,全 demo 信息密度最高的一页:每渠道一行——供应商 / 承载模型 / 健康三态(健康 · 半开观察 · 熔断中带倒计时) / P50/P95 / 24h 错误率 / 上游余额(余额告警是真实运营刚需) / 权重·优先级就地编辑。熔断行整行泛红,半开行泛黄——状态不用找,扫一眼就有。

2.4 模型目录(P1 概念页)

TOKEN 运营平台

模型目录

模型名称	所属赛道	成本价(CNY/h)	零售价(CNY/h)	毛利	状态
deepseek-vl	DG-火山 · DG-官方 · DG-轻量	2.0 / 8.0	2.4 / 9.6	20%	在售
qwen-gpt	Qwen-百度 · Qwen-官方	0.8 / 2.0	1.0 / 2.5	20%	在售
kimi-k2	Kimi-官方 · Kimi-鲁南	5.0 / 10.0	6.0 / 16.0	20%	即将上线
glm-l	GLM-官方 · GLM-轻量	4.0 / 12.0	4.8 / 14.4	20%	在售

Token 运营平台

[查看模型目录](#) | [查看模型使用指南](#) | [联系我们](#) | [加入我们](#)

运营视角的"卖什么、挣多少":对外模型 → 背后供给渠道 → 成本价 → 售价 → **毛利率** → 在售状态。与租户端的模型目录同源不同视角:客户看价格与性能,运营看毛利与供给冗余。

2.5 路由策略(P1 概念页)



智能路由的运营面呈现:候选过滤(剔除熔断 + 合规标签匹配)→ 打分权重(成本/延迟/余量)→ Fallback 链 → 灰度放量 → 24h 策略命中统计。把 roadmap 里 L0~L4 路由谱系的"当前档位"翻译成可调整、可回溯(版本历史)的运营对象。

2.6 计费对账(P1 概念页)



财务的主页面,三列对账:① 上游账单(供应商实扣)↔ ② 平台逐 token 计量 ↔ ③ 客户账单(分摊),差异 >0.5% 自动标红可下钻。这页的原型是真实做过的月度对账动作——把"Excel 苦役"变成常驻看板,也是"毛利"数字可信的根基。

2.7 观测中心 · 请求日志(P0)

Token 运营平台

运营看板

概览

用户管理

渠道管理

模型自采

路由策略

计费对账

观测中心

审计

观测中心 · 请求日志

按租户 / Key / 模型 / trace-id 筛选

请求状态

请求详情

时间	租户 / Key	模型	路由策略	请求来源	耗时	费用	状态
14:05:11	星桥科技 / ai-723***	deepseek-v3	DS-火山	1204 / 812	1.8s	¥0.0062	● 200
14:05:08	星桥科技 / ai-723***	qwen-72b	Qwen-官方	3480 / 1,041	9.9s	¥0.0417	● 200
14:05:08	星桥科技 / ai-723***	qwen-72b	Qwen-官方	645 / 320	0.8s	¥0.0031	● 200
14:05:05	星桥科技 / ai-723***	qwen-72b	Kimi-备用 → Kimi-官方	1213 / 388	5.2s	¥0.0201	● 200(重试)
14:05:03	星桥科技 / ai-723***	qwen-72b	DS-火山	11 / 1	30.0s	¥0	● 504

点击任意行查看更多 Trace 详情: 按时间排序 → 上游耗时拆解 → 逐 token 计量明细, 交互对齐 Langfuse

11:00am - 12:00pm 今天 | 查看历史数据 | 刷新 | 帮助

故障入口:按租户/Key/模型/trace-id 筛选,行内直接看到路由渠道(含"Kimi-备用 → Kimi-官方"的 fallback 痕迹)与状态(200 重试 / 504)。点行进 Trace 详情:路由决策依据 → 上游耗时拆解 → 逐 token 计量明细,交互对齐 Langfuse。

2.8 审计(P3 概念页)

Token 运营平台

运营看板

概览

用户管理

渠道管理

模型自采

路由策略

计费对账

观测中心

审计

审计

按租户 / Key / 模型 / trace-id 筛选

请求状态

请求详情

时间	租户 / Key	模型	路由策略	请求来源
14:05:11	星桥科技 / ai-723***	deepseek-v3	DS-火山	1204 / 812
14:05:08	星桥科技 / ai-723***	qwen-72b	Qwen-官方	3480 / 1,041
14:05:05	星桥科技 / ai-723***	qwen-72b	Kimi-备用 → Kimi-官方	1213 / 388
14:05:03	星桥科技 / ai-723***	qwen-72b	DS-火山	11 / 1

点击任意行查看更多 Trace 详情: 按时间排序 → 上游耗时拆解 → 逐 token 计量明细, 交互对齐 Langfuse

11:00am - 12:00pm 今天 | 查看历史数据 | 刷新 | 帮助

管理员视角的操作留痕:谁在何时改了什么配置、影响面是什么(权重调整 → 流量再平衡;自动熔断 → 供给降级)。P3 阶段交付,demo 中仅示意数据形态。

3. 租户控制台 —— 逐页设计说明(对标 OpenRouter 客户侧)

对标基准:OpenRouter 2026-08 现行 workspace 制控制台(实测)。其客户侧能力面 = API Keys / Activity / Logs / Credits / Routing / Guardrails / BYOK / Presets / Observability 等;下列各页标注对应关系, v2 新增 为按最新实测补齐的页面。

3.1 用量总览 对标 Activity + Logs



客户的第一屏:消费/预算进度 → 请求与成功率 → token 量与缓存命中率 → **混合单价 ¥/M tok**(v2 新增,直接呼应智能路由的降本承诺:"上月 ¥2.61 → 本月 ¥2.32")→ 首字延迟与路由开销。下方按模型堆叠的每日消费图 + 可下钻的请求明细(明细抽屉含路由开销拆解与结束原因,对标 OpenRouter Logs 的 Routing Overhead / Finish Reason 字段)。

3.2 模型目录 对标 Models



OpenRouter Models 页形态:价格/上下文/实时性能(P50 首字、吞吐)/供给渠道数一屏可比,叠加"本月你的用量"个性化;差异化是"可私有化/供给降级"标签——国内 2B 合规刚需的显性化。全国产模型口径。

对标 Keys

API Keys

名称 / ID	所属设备	设备状态	到期时间	当前余额	过期	状态	操作
生产主 Key pk-123456789	服务器组A	已启用	¥20,000	¥18,220(91%)	2024-12-31	● 正常	复制 删除 详情
测试 Key pk-987654321	开发机组B	已禁用	¥500	¥310(62%)	永不	● 停用	复制 详情
营销 Key pk-321098765	营销渠道C	已禁用	¥1,500	\$4,800(81%)	2024-09-30	● 停用	复制 删除

Key 信息管理：实时监控所有 API 密钥的状态、余额及有效期，支持批量操作。

[查看日志](#) | [管理设备](#) | [充值续费](#) | [联系客服](#)

Key 管理:名称/所属项目/治理策略标签(v2 新增列,点击可跳策略详情)/限额与已用/过期时间(v2 新增列,对齐 OpenRouter Key 的 Expires 字段)/启停操作。Key 归属项目、项目归属租户,限额由所挂策略统一定义并在网关硬执行。

对标 Credits

本月计划

¥23,410

预算差异 30天，环比

实际

¥30,000

超出预算 66.7% (环比)

历史最佳

¥1,204

超出预算 24.4%

日期	实际金额	计划	差异	备注
2025-08 (进行中)	¥23,410	计划中	—	最近数据
2025-07	¥28,360	超预期	超预期	最近数据
2025-06	¥18,920	超预期	超预期	最近数据

[查看历史](#) | [查看详细数据](#) | [导出数据](#) | [帮助中心](#)

2B 化的 Credits:OpenRouter 是预付 credits + 自动充值,我们改为月结账期/对公/发票下载/明细导出——同一能力位,按国内企业采购习惯重做交易形态;保留"缓存累计节省"作为平台价值的持续提示。

3.5 路由偏好 对标 Routing + BYOK + Presets



租户级路由自助:成本/质量权衡滑杆(对标 Auto Router 的 Cost Tier)、Failover 开关、数据合规约束(对标 ZDR/Regional routing,本土化为"数据不出域/仅私有化渠道")、语义缓存项目级开关、场景绑定,v2 新增 **BYOK** 行(客户自带供应商直签 Key,优先扣自有额度、异常回退平台池——对齐 OpenRouter BYOK 的 key priority & fallback 语义)与 **Presets** 行(提示词+模型+参数模板,API 按名引用)。

3.6 治理策略 v2 新增 对标 Guardrails



OpenRouter 2026 年新主推的治理抽象,原样借入:把"消费限额 + 数据约束 + 模型白名单 + 超限动作(告警/熔断)"打包成可复用策略对象挂到 Key 上,租户默认策略自动套用全部未挂载 Key。本土化差异:策略维度增加数据出域约束与输入输出留存审计(等保场景),并提供"命中记录"下钻。这是企业管理员管几十个 Key 的刚需,也是相对 credits 制卖品的治理深度差异。

3.7 可观测性

v2 新增

对标 Observability



数据回流客户自有系统:输入/输出日志留存开关(默认关,仅计量元数据)+ 零埋点日志外发——网关自动把每条请求 trace 推送到客户自己的观测平台。OpenRouter 的 Broadcast 支持 19 类目的地(Langfuse/Datadog/S3 等);国内首发目的地选自建 Langfuse / 阿里云 SLS / OSS-S3 / 签名 Webhook。企业客户"数据必须回我自己系统"的采购门槛项。

3.8 接入文档

对标 Quickstart



60 秒接入:OpenAI 兼容协议,存量代码只改 base_url 与 Key 零改造迁移;Anthropic 兼容端点、流式、工具调用在完整文档中(demo 略)。迁移成本是采购决策的第一道门槛,所以做成独立导航项而非埋在帮助中心。

4. v2 迭代记录

基于对 OpenRouter 现行控制台(已登录租户视角)的逐页实测:其已改版为 **workspace 制**,能力面在我们 v1 十项映射之上新增了 Guardrails、Observability(Broadcast)、Presets、Plugins、Classifiers 等。本次按"对路演故事的支撑度"取舍:

改动	内容	对应 OpenRouter 能力
新增页	治理策略(策略包挂 Key、默认策略、命中记录)	Guardrails
新增页	可观测性(留存开关 + 四类外发目的地)	Observability / Broadcast
总览增强	混合单价 ¥/M tok KPI、缓存命中率上卡面;明细抽屉加路由开销与结束原因	Activity 的 Blended \$/1M、Logs 的 Routing Overhead / Finish Reason
Keys 增强	治理策略列 + 过期时间列	Keys 表的 Guardrails / Expires 列
路由偏好增强	BYOK 行、Presets 行;文案对齐 Auto Router	BYOK、Presets、openrouter/auto
双端标注	两 demo 顶部横幅写明各自视角并互链	—

刻意未做:Files、Classifiers、Server Tools、Plugins(联网搜索/PDF 解析/JSON 修复)、Management Keys(编程管 Key 的 admin API)、加密充值——或与路演主线无关,或属 P2+ 能力,避免 demo 失焦。

5. Demo 的边界声明

- **纯前端、模拟数据**:所有数字为演示编排,不代表真实计量;按钮操作以 toast 提示代替真实写入。
- **演示目标是信息架构与交互形态**:真实实现的数据来源、接口契约与分期,以《token-platform-roadmap》为准(L0—L4 路由谱系、12 个月 roadmap、Go 自研网关方案)。
- **阶段徽章即承诺边界**:demo 中标注 P1/P3 的页面为概念页,P0 页面对应第一个月可交付范围(2—3 人,¥5—7 万/人月口径)。